

De la donnée capteur à la décision opérationnelle

Séquence 4 – Qualité des données et incertitude

École de l'air et de l'espace

Bienvenue dans la séquence 4

Ce que nous ajoutons aujourd'hui

Jusqu'ici, nous avons supposé que les valeurs numériques présentes dans un message étaient au moins plausibles. Aujourd'hui, nous arrêtons de le supposer.

- ▶ Une valeur peut être présente sans être valide : un champ manquant ailleurs dans le même message, une unité incohérente, ou une valeur physiquement impossible peuvent toutes se cacher derrière un nombre d'apparence normale.
- ▶ Un silence dans une chronologie de mesures peut être un vrai manque de message, ou seulement la conséquence du rejet d'une ligne invalide : ces deux silences se ressemblent, mais n'appellent pas la même vérification.
- ▶ Nous allons construire, sur nos propres données, la différence entre ces deux formes de silence – et voir pourquoi la confondre peut fausser une décision.

Le fil rouge des huit séquences

Donnée capteur imparfaite



Pipeline de traitement



aujourd'hui : le filtre qualité

Indicateur



Décision opérationnelle

La séquence 1 a construit une pipeline sans jamais interroger la validité des valeurs qu'elle transportait. La séquence 4 ajoute précisément l'étape qui manquait : avant de calculer quoi que ce soit, décider ce qui a le droit d'entrer dans le calcul.

Ce que vous saurez faire à la fin de cette séquence

1. nommer et détecter quatre types d'erreurs de contenu : champ manquant, unité incohérente, valeur hors plage physique, incohérence temporelle ;
2. séparer les messages propres des messages rejetés sans jamais corriger silencieusement une valeur ;
3. distinguer un silence réel dans une chronologie d'un silence simplement expliqué par une ligne rejetée ;
4. relier un silence non expliqué à la confiance que l'on peut accorder à une valeur qui le suit ;
5. recommander une action avec confiance, preuves, incertitudes et vérification terrain.

La question qui guidera la séance

Question décisionnelle

À partir de quel niveau d'erreur et de silence une alerte température devient-elle insuffisante pour agir seule ?

- ▶ Nous ne cherchons pas un seuil universel d'erreur acceptable, mais une méthode pour qualifier, cas par cas, ce qu'un lot de données permet réellement d'affirmer.
- ▶ Une même valeur d'alerte peut être défendable ou fragile selon ce qui l'entoure : son contexte, ses voisines, et surtout les silences qui la précèdent.
- ▶ Le raisonnement compte autant que la conclusion : deux décisions différentes peuvent être également recevables si les preuves et les limites sont explicites.

Section 1

Une alerte, et rien d'autre

Avant d'ouvrir le moindre fichier, nous décidons avec l'information la plus pauvre possible : une phrase.

Le scénario : une alerte apparaît

Une supervision transmet un message unique :
« battery-shelter-01 a atteint 36,2 °C,
au-dessus du seuil habituel. » Aucune autre
information n'accompagne cette phrase.

Contrainte de décision

Vous ne savez ni si cette valeur est
isolée, ni si elle a été précédée d'un
silence, ni si le message qui la
porte respecte les règles de qualité
que nous allons définir.

La première question n'est donc pas « la valeur est-elle haute ? », mais « cette valeur
est-elle même une donnée sur laquelle on peut raisonner ? »

Avant de regarder les données : votre décision

Choisissez une réponse :

- A. l'alerte est exploitable telle quelle ;
- B. il faut d'abord contrôler la qualité des données ;
- C. maintenir l'activité par prudence en attendant ;
- D. suspendre l'activité par prudence en attendant.

Notez également :

- ▶ votre confiance de 0 à 100 % ;
- ▶ votre raison principale ;
- ▶ l'information qui vous manque le plus.

Ce vote initial sera comparé au vote final, une fois le contrôle qualité effectué sur les données réelles.

Une valeur n'est pas encore une donnée validée

Valeur un nombre, isolé de tout contrôle : « 36,2 ».

Message cette valeur replacée dans un message complet, avec un champ censé porter son unité, son horodatage et sa zone.

Donnée validée un message dont chaque champ obligatoire est présent, dont l'unité est reconnue, et dont la valeur reste physiquement plausible.

Décision une action choisie en tenant compte de ce que la donnée validée permet, ou non, d'affirmer.

Le piège de cette séquence

Un message peut franchir les trois premières étapes en apparence – il ressemble à un message normal – tout en échouant silencieusement à l'une d'elles. Nous allons apprendre à le détecter avant qu'il n'atteigne une décision.

Auto-vérification avant de continuer

Une alerte réduite à une seule phrase prouve-t-elle quoi que ce soit sur la qualité de la donnée qui la porte ?

Non : elle ne dit rien sur la présence de tous les champs attendus, sur la cohérence de l'unité, ni sur la plausibilité physique de la valeur. Ces propriétés ne se voient qu'en examinant le message complet.

Pourquoi distinguer « valeur », « message » et « donnée validée » ?

Parce qu'une même valeur numérique peut appartenir à un message par ailleurs invalide : la valeur seule ne suffit jamais à juger de la qualité de l'ensemble.

Section 2

Quatre qualités d'une donnée

Avant de coder le moindre contrôle, nous devons savoir précisément ce que chaque contrôle est censé vérifier.

Validité

Définition

La ligne respecte les règles déclarées : chaque champ obligatoire est présent, l'unité appartient au vocabulaire attendu, et la valeur reste dans une plage physiquement plausible.

- ▶ **Piège fréquent** : confondre « le champ existe dans le JSON » avec « le champ contient une valeur correcte ».
- ▶ **Effet sur la décision** : une ligne invalide ne doit jamais entrer dans un calcul d'indicateur sans avoir été signalée au préalable.

Question décisionnelle

Un message peut-il être syntaxiquement correct – un JSON qui se parse sans erreur – tout en étant invalide au sens de cette séquence ?

Définition

Tout ce qui était attendu sur une période donnée est effectivement arrivé : aucune zone, aucun instant de mesure attendu ne manque silencieusement.

- ▶ **Piège fréquent** : confondre un message reçu puis rejeté avec un message qui n'a jamais été reçu du tout.
- ▶ **Effet sur la décision** : un vrai manque de transmission et un rejet de qualité n'appellent pas la même vérification terrain.

Nous reviendrons sur ce piège précis dans l'incident de fin de séance : c'est le cœur de la séquence.

Cohérence

Définition

Les champs d'une même ligne, ou de lignes voisines dans le temps, ne se contredisent pas entre eux.

Exemple réel du lot

Un message de `it-room-01` déclare `measured_at = 2026-10-19T10:15:00Z` alors qu'il a été `received_at = 2026-10-19T09:55:00Z`, soit vingt minutes *avant* l'instant où il prétend avoir été mesuré. Une mesure ne peut pas être reçue avant d'avoir eu lieu.

Effet sur la décision : une incohérence temporelle invalide la ligne entière ; elle ne se corrige pas en gardant une seule des deux horloges.

Définition

La mesure reflète un ordre de grandeur physiquement crédible pour le contexte décrit – ici, la température ambiante d'un abri sur une base aérienne.

- ▶ **Piège fréquent** : croire qu'une valeur numérique plausible en apparence est forcément exacte physiquement.
- ▶ **Effet sur la décision** : aucun contrôle automatique de cette séquence ne peut démontrer l'exactitude d'une mesure ; il peut seulement écarter ce qui est physiquement impossible.

Rejeter une valeur hors plage n'est pas la même chose que valider les valeurs restantes : cela ne fait qu'écarter le pire des cas.

Un exemple filé : le message incomplet d'it-room-01

```
{"topic":"airbase/batch002/it-room-01/temperature/0002",  
  "received_at":"2026-10-19T09:51:00Z","retained":true,  
  "payload":{"batch_id":"alert-window-002","message_id":"it-room-01-0002",  
    "site_id":"base-projetee-alpha","zone":"it-room-01","asset_type":"tactical_it",  
    "sensor":"temperature","measured_at":"2026-10-19T09:50:00Z",  
    "value":31.4,"sequence":2}}
```

Le champ `unit` est absent de ce payload. La valeur 31.4 est présente, plausible, et pourtant ce message est invalide : sans unité déclarée, 31.4 ne veut rien dire.

Auto-vérification avant de continuer

Validité et précision sont-elles la même qualité ?

Non : la validité contrôle la forme et la plausibilité déclarative (champs, unité, plage) ; la précision porterait sur l'exactitude physique réelle, que nos contrôles ne peuvent pas démontrer.

Pourquoi un message avec un JSON parfaitement valide peut-il être invalide au sens de cette séquence ?

Parce que la validité JSON ne garantit ni la présence de chaque champ métier obligatoire, ni la cohérence entre ses champs, ni la plausibilité physique de sa valeur.

Que retenir du message d'`it-room-01` ci-dessus ?

Qu'une valeur présente et plausible ne suffit pas : l'absence du seul champ `unit` rend toute la ligne invalide, malgré une valeur en apparence normale.

Section 3

TP 1 – Détecter les erreurs

Vous allez maintenant appliquer les quatre contrôles à la fenêtre réelle de 24 messages.

Démonstration : lancer le contrôle qualité

```
from iot_decision.quality import load_raw, flatten, validate_row
rows = [flatten(e) for e in load_raw('data/samples/batch002_quality_messages.jsonl')]
for r in rows:
    reason = validate_row(r)
    if reason:
        print(r['message_id'], '->', reason)
```

Ce script s'exécute dans le notebook de la séquence, après export `PYTHONPATH=src`. Avant de le lancer, prédisez : combien de messages seront signalés, et pour quels types de raisons ?

Activité B / TP 1 – Détecter sans corriger

Votre mission

Exécuter le contrôle qualité sur les 24 messages et documenter chaque ligne signalée.

1. exécuter la commande de détection ;
2. relever, pour chaque ligne signalée, son `message_id` et sa raison exacte ;
3. classer les raisons en quatre catégories : champ, unité, valeur, temps ;
4. pour chacune, identifier le champ ou la valeur précisément en cause ;
5. ne modifier aucun fichier source pendant cette étape.

Livrable et décision

Un tableau des lignes signalées et une phrase : « Ce lot contient au moins ... type(s) d'erreur distincts. »

Ce que révèle le contrôle qualité

Message	Zone	Raison exacte
it-room-01-0002	it-room	champ manquant : unit
maintenance-zone-01-0002	maintenance	unité incohérente : fahrenheit
optronics-shelter-01-0002	optronics	valeur hors plage physique : 214,7
it-room-01-0003	it-room	incohérence temporelle
comms-shelter-01-0001	comms	doublon exact (2e occurrence de la même publication)

Cinq lignes rejetées sur vingt-quatre, une par type de contrôle, réparties sur quatre zones différentes.

Zoom : l'unité incohérente

Le message maintenance-zone-01-0002 déclare value = 86.9 avec unit = "fahrenheit", au milieu de quatre autres messages de la même zone tous exprimés en Celsius.

Le calcul qui aurait été silencieusement faux

86,9 °F correspond à environ 30,5 °C – une valeur en fait cohérente avec ses voisines. Sans le contrôle d'unité, ce message aurait été traité comme 86,9 °C : une aberration invisible dans un tableau, mais catastrophique dans un calcul de maximum.

Nous ne convertissons jamais silencieusement l'unité : nous rejetons et documentons, pour que l'erreur de configuration reste visible.

Zoom : la valeur hors plage physique

Le message `optronics-shelter-01-0002` déclare `value = 214.7` en celsius, entouré de quatre valeurs voisines entre 27,9 et 28,3 °C.

Bornes retenues pour cette séquence

-10 °C à 60 °C. Ce ne sont pas des bornes officielles ni une spécification du fabricant : ce sont des bornes pédagogiques, à faire valider par le responsable du matériel avant tout usage réel.

Question décisionnelle

Si cette valeur n'avait pas été écartée, quel effet aurait-elle eu sur le maximum calculé pour cette zone ?

Le doublon exact : une retransmission, pas un candidat

Le message `comms-shelter-01-0001` apparaît deux fois dans le brut : même topic, même `message_id`, même mesure, même horodatage de mesure – seul l'instant de réception diffère de quatre secondes.

Deux sortes de ressemblance, à ne jamais confondre

Un *candidat* doublon partage des valeurs semblables mais porte des identifiants différents : on ne le supprime jamais sans règle explicite, car deux capteurs distincts peuvent légitimement mesurer la même valeur au même instant. Ici, c'est l'inverse : l'identifiant, le topic et la mesure sont rigoureusement identiques – une retransmission du même événement, probablement liée au mécanisme de re-livraison de MQTT.

Ce cas précis est le seul de cette séquence où retirer une ligne ne perd aucune information : les deux occurrences décrivent le même événement, pas deux événements distincts.

Débrief – quelles erreurs sont graves pour la décision ?

1. Classez les cinq erreurs détectées de la plus grave à la moins grave pour la décision concernant battery-shelter-01.
2. Une erreur sur une zone différente de celle en alerte a-t-elle la même gravité qu'une erreur sur la zone en alerte elle-même ?
3. Le doublon exact aurait-il faussé un décompte s'il n'avait pas été détecté ? Dans quel sens ?
4. Une ligne rejetée est-elle perdue pour l'analyse, ou seulement exclue du calcul ?

Une ligne rejetée reste dans rejected.csv avec sa raison : elle quitte le calcul, jamais le dossier de preuve.

Auto-vérification avant de continuer

Pourquoi ne pas convertir silencieusement 86,9 °F en Celsius plutôt que rejeter le message ?

Parce que corriger silencieusement masquerait l'erreur de configuration qui a produit cette unité incorrecte, et empêcherait de la détecter ailleurs dans le système.

En quoi le doublon exact de `comms-shelter-01` diffère-t-il d'un simple candidat doublon ?

Un candidat doublon partage des valeurs semblables avec des identifiants différents et reste ambigu ; le doublon exact ici partage un identifiant, un topic et une mesure rigoureusement identiques : c'est la même publication reçue deux fois.

Section 4

Rejet, correction, quarantaine

Détecter une erreur ne dit pas encore quoi en faire : trois réponses sont possibles, une seule est appliquée ici.

Rejet, correction, quarantaine

Rejet écarter la ligne du calcul, en conservant sa trace complète et sa raison exacte dans un fichier séparé.

Correction remplacer une valeur jugée fautive par une valeur jugée plus probable, silencieusement ou explicitement.

Quarantaine isoler une ligne ambiguë sans la valider ni la rejeter définitivement, en attendant un avis humain ou une vérification externe.

Choix retenu dans cette séquence

Le rejet, systématiquement documenté. Aucune correction automatique n'est appliquée : convertir une unité ou ajuster une valeur resterait une hypothèse, jamais une observation.

Pourquoi ce cours ne corrige jamais silencieusement

- ▶ Une correction silencieuse remplace une observation par une hypothèse, sans que quiconque relisant le fichier plus tard ne puisse s'en rendre compte.
- ▶ Elle rend impossible la détection d'un problème récurrent : si l'unité Fahrenheit est corrigée automatiquement partout, personne ne remarquera qu'un capteur reste mal configuré.
- ▶ Elle transfère silencieusement la responsabilité du jugement de l'humain vers un script, sans trace du raisonnement suivi.

Question décisionnelle

Existe-t-il un cas, dans ce lot, où une quarantaine aurait été plus appropriée qu'un rejet ferme ?

Démonstration : produire clean.csv et rejected.csv

```
python3 -m iot_decision.quality_cli \  
  data/samples/batch002_quality_messages.jsonl \  
  data/processed/batch002_measurements_clean.csv \  
  data/processed/batch002_rejected.csv \  
  data/processed/batch002_quality_report.json
```

Une seule commande produit les trois sorties à partir de la même source et du même calcul, pour qu'elles ne puissent jamais se désaccorder entre elles.

Activité D / TP 2 – Séparer sans corriger

Votre mission

Produire `clean.csv` et `rejected.csv`, puis vérifier qu'aucune valeur n'a été modifiée.

1. exécuter la commande de séparation ;
2. vérifier les 19 lignes propres et les 5 lignes rejetées ;
3. comparer chaque valeur de `rejected.csv` à sa ligne d'origine dans le brut ;
4. confirmer qu'aucune valeur n'a changé, seule une raison a été ajoutée ;
5. produire la chronologie figurée à partir des deux fichiers.

Livrable et décision

Les deux CSV et une phrase : « Ce lot propre est-il suffisant pour comparer les zones ? Pourquoi ? »

Lire un contrôle de qualité minimal

- ▶ 24 lignes brutes attendues : si ce nombre diffère, le fichier source a changé.
- ▶ 19 lignes propres et 5 rejetées attendues : la somme doit toujours retomber sur 24.
- ▶ cinq raisons de rejet distinctes attendues : une seule occurrence de chaque type sur ce lot précis.
- ▶ aucune valeur modifiée entre le brut et `rejected.csv` : seule une colonne supplémentaire est ajoutée.
- ▶ toutes les colonnes d'origine conservées dans `clean.csv` : topic, réception et retained compris.

Question décisionnelle

Le fichier propre est-il exempt de toute erreur, ou seulement des cinq erreurs que nos quatre contrôles savent détecter ?

Auto-vérification avant de continuer

Pourquoi produire les trois fichiers – propre, rejeté, rapport – en un seul appel de commande ?

Parce qu'ils partagent la même source et le même calcul : les produire séparément risquerait un désaccord entre eux si l'un était régénéré sans les autres.

Que perd-on en supprimant `rejected.csv` après la séance ?

La preuve que ces cinq lignes ont existé et la raison précise de leur exclusion : toute contestation future deviendrait impossible à instruire.

Section 5

Le silence de battery-shelter-01

Nous revenons maintenant à la zone en alerte, avec les preuves construites depuis le début de la séance.

Incident – quatre silences détectés

```
python3 -m json.tool data/processed/batch002_quality_report.json
```

Le rapport signale un silence – un écart de plus de sept minutes entre deux mesures propres consécutives – sur quatre zones : battery-shelter-01, it-room-01, maintenance-zone-01 et optronics-shelter-01.

Question décisionnelle


Ces quatre silences ont-ils tous la même origine ?

Silence réel ou effet du filtrage ?

Zone	Silence	Expliqué ?	Explication
battery-shelter-01	20 min	non	aucune ligne rejetée dans cette zone
it-room-01	15 min	oui	deux lignes rejetées dans la fenêtre
maintenance-zone-01	10 min	oui	une ligne rejetée (unité incohérente)
optronics-shelter-01	10 min	oui	une ligne rejetée (valeur hors plage)

Trois silences sur quatre s'expliquent entièrement par une ligne que nous avons nous-mêmes rejetée : ce n'est pas un message perdu en transit, c'est un message reçu puis écarté pour une raison déjà documentée. Un seul silence reste sans explication.

La chronologie de la fenêtre d'alerte



Ce que le silence de battery-shelter-01 signifie

Ce que nous observons

Dernière mesure propre à 9 h 45 (34,6 °C), puis un silence de vingt minutes sans aucun message reçu pour cette zone, puis une reprise à 10 h 05 avec une valeur de 36,2 °C – au-dessus du seuil pédagogique de 35 °C.

Ce que nous ne pouvons pas affirmer

Ni que la température a grimpé progressivement pendant ce silence, ni qu'un incident technique a interrompu la transmission, ni que la valeur de reprise est exacte : le silence laisse ces trois hypothèses ouvertes.

Activité F – Brief décisionnel et vote final

Votre mission

Rédiger une recommandation de 150 mots maximum à partir des trois fichiers produits.

1. choisir une action concrète et son périmètre ;
2. qualifier la confiance ;
3. citer deux preuves chiffrées et retrouvables (fichier et champ) ;
4. citer deux incertitudes qui pourraient changer la décision ;
5. proposer une vérification terrain ou technique prioritaire.

Règle de restitution

Le silence réel de battery-shelter-01 doit apparaître explicitement dans votre argumentation, pas seulement la valeur de 36,2 °C.

Ce que cette séquence permet

Nous pouvons déjà

nommer et localiser quatre types d'erreurs de contenu, séparer propre et rejeté de façon traçable, et distinguer un silence réel d'un silence expliqué par nos propres rejets.

Nous ne pouvons pas encore

expliquer la cause du silence réel de battery-shelter-01, certifier l'état actuel de cette zone, ni garantir qu'aucune autre erreur, non couverte par nos quatre contrôles, ne subsiste dans le lot propre.

Auto-vérification avant de continuer

Un silence expliqué par un rejet est-il sans importance pour la décision ?

Non : il reste un signal sur la qualité de la source à surveiller ; il n'est simplement pas un signal d'absence de transmission comme celui de `battery-shelter-01`.

Peut-on affirmer que `battery-shelter-01` est en panne à partir de ce seul silence ?

Non : le silence a plusieurs causes possibles – panne, coupure de transmission, filtre d'extraction incorrect, ou hausse réelle simplement non enregistrée – que seule une vérification terrain ou technique peut départager.

Transition vers la suite du cours

Les prochaines séquences s'appuieront directement sur ce réflexe de qualité :

1. les indicateurs et leurs pièges d'agrégation, y compris quand la donnée sous-jacente est déjà propre ;
2. la visualisation et la communication d'une incertitude sans donner une fausse impression de certitude ;
3. la sécurité et la robustesse de toute la chaîne de collecte, en amont même de nos contrôles de qualité.

Le rapport qualité produit aujourd'hui restera une pièce du dossier de preuve pour toute décision future concernant ce lot.

Activité G – Synthèse individuelle

Complétez les trois phrases, seul et sans écran :

1. Le contrôle qualité permet d'affirmer que ...
2. Il ne permet pas d'affirmer que ...
3. Avant une action irréversible, je vérifierais ...

Valeur → validité → silence réel ou expliqué → décision → confiance.

Ce que la séance a permis d'établir – synthèse de référence

Résultat de référence sur ce lot

24 messages bruts, 19 lignes propres, 5 lignes rejetées (une par type de contrôle). Un seul silence sur quatre détectés est réel : celui de battery-shelter-01, vingt minutes sans message, immédiatement suivi d'une valeur de 36,2 °C au-dessus du seuil pédagogique.

Une recommandation défendable, à titre d'exemple

Vérification terrain prioritaire de battery-shelter-01 avant toute conclusion sur une tendance, avec une confiance qualifiée de *faible* : la valeur haute est propre, mais rien n'explique le silence qui la précède directement.

D'autres formulations restent recevables si elles distinguent explicitement silence réel et silence expliqué par un rejet, et si elles proportionnent l'action à cette seule incertitude documentée.

Références et ressources

- ▶ ISO 8000-8, *Information and data quality – Concepts and measuring* – cadre de référence pour validité et complétude : <https://www.iso.org/standard/60805.html>
- ▶ OASIS, *MQTT Version 5.0* – retransmission et mécanisme retenu pour le doublon exact : <https://docs.oasis-open.org/mqtt/mqtt/v5.0/os/mqtt-v5.0-os.html>
- ▶ JCGM 100 :2008, incertitude de mesure : <https://www.bipm.org/en/committees/jc/jcgm/publications>
- ▶ NISTIR 8286A Rev. 1, gestion du risque appliquée aux systèmes d'information : <https://doi.org/10.6028/NIST.IR.8286Ar1>
- ▶ Python, bibliothèques json et csv : <https://docs.python.org/3/library/json.html>
- ▶ Matplotlib, documentation : <https://matplotlib.org/stable/>