

Syllabus

De la donnée capteur à la décision opérationnelle

Qualité, confiance et incertitude dans une pipeline IoT

École de l'air et de l'espace - Module de 8 séquences de 4 h

Intention pédagogique

Former des décideurs capables d'exercer un esprit critique face aux données, aux indicateurs et aux décisions qu'une pipeline de données peut soutenir ou fragiliser.

Données capteurs imparfaites -> pipeline de traitement -> indicateurs -> décision opérationnelle -> niveau de confiance, incertitude et risques

1. Contexte général

Ce cours s'inscrit dans un projet plus large autour d'une chaîne IoT : des Arduino équipés de shields LoRa produisent ou transmettent des données de capteurs, qui sont ensuite récupérées, transformées, analysées et utilisées pour éclairer une prise de décision.

Le cours est destiné à des officiers ou élèves officiers de l'École de l'air et de l'espace. L'objectif n'est pas de former des experts en ETL, en programmation ou en infrastructure informatique, mais de développer une compréhension critique du rôle des pipelines de données dans la qualité d'une décision opérationnelle.

Question centrale

Les données disponibles permettent-elles de prendre une décision fiable : maintenir l'activité prévue, déclencher une inspection, protéger du matériel, différer une opération ou demander une vérification terrain ?

2. Use case opérationnel fil rouge

Le scénario pédagogique retenu est celui d'une base aérienne projetée équipée de capteurs environnementaux simples. Des capteurs Arduino/LoRa mesurent régulièrement la température dans plusieurs zones critiques :

- stockage batteries de drones ;
- shelter transmissions ;
- local informatique tactique ;
- zone de maintenance légère ;
- abri matériel optronique.

Dans la première version du cours, on suppose que le broker MQTT contient déjà des données. Les étudiants travaillent sur un broker simulé, pré-rempli avec des messages de température. Le scénario permet de travailler des situations réalistes sans données sensibles : capteur défaillant, données manquantes, dépassement de seuil, indicateur trompeur, contradiction entre capteurs, ou problème de confiance dans le flux de données.

3. Objectifs pédagogiques

1. Comprendre le rôle d'un broker MQTT dans une architecture IoT.
2. Expliquer comment une donnée capteur brute devient un indicateur décisionnel.
3. Extraire des messages depuis un broker simulé et conserver les données brutes.
4. Parser et structurer des messages JSON.
5. Identifier les erreurs de données : valeurs manquantes, doublons, timestamps incohérents, unités incorrectes, valeurs aberrantes.
6. Transformer des données brutes en table exploitable.
7. Produire des indicateurs simples : moyenne, maximum, durée de dépassement, taux de données manquantes, nombre de rejets.
8. Interpréter ces indicateurs dans un contexte opérationnel.
9. Identifier les indicateurs utiles, insuffisants ou trompeurs.
10. Évaluer le niveau de confiance associé à une décision.
11. Formuler une recommandation opérationnelle argumentée, avec limites et vérifications terrain nécessaires.

4. Positionnement pédagogique

Le cours n'est pas centré sur la maîtrise technique exhaustive des outils. Les outils servent de support pour comprendre les effets d'une chaîne de traitement sur la décision.

Chaque séance suit la logique suivante :

Concept technique -> conséquence sur la donnée -> conséquence sur l'indicateur -> conséquence sur la décision -> niveau de confiance

Exemple

Doublon -> message compté deux fois -> durée d'alerte surestimée -> inspection déclenchée à tort -> confiance réduite.

5. Architecture pédagogique retenue

Dans la première version du cours, il n'y a pas de flux continu réel. On utilise un broker MQTT simulé, déjà rempli avec des données de température.

```
Broker MQTT Mosquitto pré-rempli
-> extraction des messages retained
-> fichier brut JSONL
-> transformation Python
-> fichier propre CSV / Parquet
-> analyse et visualisation
-> recommandation opérationnelle
```

Exemples de topics MQTT :

```
airbase/batch001/battery-shelter-01/temperature/0000
airbase/batch001/battery-shelter-01/temperature/0001
airbase/batch001/comms-shelter-01/temperature/0000
airbase/batch001/maintenance-zone-01/temperature/0000
```

6. Exemple de message capteur

```
{
  "batch_id": "mission-readiness-001",
  "message_id": "battery-shelter-01-0042",
  "site_id": "base-projetee-alpha",
  "zone": "battery-shelter-01",
  "asset_type": "drone_battery_storage",
  "sensor": "temperature",
  "measured_at": "2026-10-12T09:35:00Z",
  "value": 34.8,
  "unit": "celsius",
  "sequence": 42
}
```

7. Outils retenus

Catégorie	Outils	Rôle
Infrastructure	VPS Ubuntu, Docker, Docker Compose, Mosquitto	Héberger le laboratoire, lancer les services, simuler le broker MQTT.
Données simulées	Messages MQTT retained	Simuler un broker déjà rempli avec un topic par mesure.
Travail depuis iPad	Safari, OVH Cloud Shell, Termius/Blink/Shelly	Administrer le VPS et accéder aux interfaces web.
Développement	code-server, JupyterLab, Git/GitHub	Coder, explorer les données, versionner et distribuer les supports.
ETL et analyse	Python, paho-mqtt, pandas, DuckDB	Extraire, parser, nettoyer, agréger et analyser les données.
Stockage et visualisation	JSONL, CSV, Parquet, matplotlib	Conserver le brut, produire des sorties propres et visualiser les résultats.
Optionnel	Node-RED, Pydantic, pytest, pyarrow, python-dotenv	Visualiser les flux, valider les messages, tester et exporter plus proprement.

8. Outils volontairement écartés

Pour garder le cours léger et centré sur la décision, on évite dans cette version : KNIME, Kafka, Spark, Airflow, Kubernetes, PostgreSQL, Grafana et TimescaleDB. Ces outils peuvent être pertinents dans des contextes industriels, mais risquent de détourner le cours vers l'infrastructure au lieu de servir l'objectif principal.

9. Déroulé détaillé des 8 séquences

Séquence 1 - Introduction et pipeline baseline

Objectif général : Comprendre le scénario opérationnel et construire une première pipeline simple de bout en bout.

Temps	Activité
0:00-0:15	Situation initiale : faut-il maintenir l'activité prévue sur la base projetée ?
0:15-0:45	Concepts : donnée, indicateur, décision, confiance, incertitude
0:45-1:10	Démonstration : broker MQTT simulé et messages de température
1:10-1:55	TP : extraire les messages vers batch001_raw.jsonl
1:55-2:05	Pause
2:05-2:30	Concepts : brut, transformé, exploitable
2:30-3:10	TP : parser les JSON et produire un CSV propre minimal
3:10-3:35	Visualisation simple de la température par zone
3:35-3:55	Décision : peut-on maintenir l'activité ?
3:55-4:00	Synthèse

Question décisionnelle : Que peut-on déjà décider avec cette pipeline minimale ? Et que ne peut-on pas encore conclure ?

Livrables : batch001_raw.jsonl ; batch001_measurements.csv ; graphique simple ; première recommandation opérationnelle.

Engagement : Vote initial puis vote final pour observer l'effet du pipeline sur la décision.

Séquence 2 - Comprendre la source : broker, topics et messages

Objectif général : Comprendre ce que contient réellement le broker et ce que l'on risque de mal interpréter dès l'extraction.

Temps	Activité
0:00-0:15	Accroche : le broker est-il une source fiable ?
0:15-0:45	Concepts : MQTT, broker, topic, payload, retained message
0:45-1:20	Exploration guidée des topics
1:20-1:55	Exercice : inventaire des zones, capteurs et messages
1:55-2:05	Pause
2:05-2:30	Concepts : lot, complétude, métadonnées
2:30-3:15	Exercice : vérifier si le lot est complet
3:15-3:40	Incident injecté : un capteur attendu est absent
3:40-3:55	Brief décisionnel : peut-on conclure ?
3:55-4:00	Synthèse

Question décisionnelle : Avant même de nettoyer les données, peut-on savoir si le lot est suffisant pour soutenir une décision ?

Livrables : Inventaire des messages ; tableau zones/capteurs ; diagnostic de complétude ; note courte sur les limites du brut.

Engagement : Binômes : équipe data et décideur qui pose des questions critiques.

Séquence 3 - Parsing, structuration et traçabilité

Objectif général : Transformer des messages techniques en données structurées tout en gardant la capacité de revenir à la source.

Temps	Activité
0:00-0:15	Situation : une décision contestée doit être justifiée a posteriori
0:15-0:45	Concepts : traçabilité, donnée brute, donnée structurée
0:45-1:25	TP : parser les payloads JSON
1:25-1:55	TP : construire une table structurée
1:55-2:05	Pause
2:05-2:30	Concepts : auditabilité, identifiants, horodatage
2:30-3:10	Exercice : relier chaque ligne propre au message brut
3:10-3:35	Incident injecté : deux messages semblent identiques
3:35-3:55	Décision : peut-on justifier l'indicateur produit ?
3:55-4:00	Synthèse

Question décisionnelle : Quelles informations doivent absolument être conservées pour pouvoir justifier une décision plus tard ?

Livrables : batch001_structured.csv ; schéma de données commenté ; justification des champs conservés.

Engagement : Mini-débat : supprime-t-on les données brutes une fois le CSV propre produit ?

Séquence 4 - Qualité des données et incertitude

Objectif général : Comprendre que la qualité des données conditionne directement le niveau de confiance dans la décision.

Temps	Activité
0:00-0:15	Accroche : une alerte température apparaît dans une zone critique
0:15-0:45	Concepts : validité, complétude, cohérence, précision
0:45-1:30	TP : champs manquants, unités incorrectes, valeurs impossibles
1:30-1:55	Débrief : quelles erreurs sont graves pour la décision ?
1:55-2:05	Pause
2:05-2:30	Concepts : rejet, correction, quarantaine, incertitude
2:30-3:15	TP : produire clean.csv et rejected.csv
3:15-3:40	Incident injecté : période critique avec données manquantes
3:40-3:55	Brief : niveau de confiance dans l'alerte
3:55-4:00	Synthèse

Question décisionnelle : À partir de quel niveau d'erreur la donnée devient-elle insuffisante pour prendre une décision fiable ?

Livrables : batch002_measurements_clean.csv ; batch002_rejected.csv ; rapport qualité ; niveau de confiance associé.

Engagement : Échelle de confiance : 0 impossible, 1 faible, 2 modérée, 3 forte.

Séquence 5 - Indicateurs, agrégations et pièges décisionnels

Objectif général : Montrer que les indicateurs simplifient la réalité et peuvent masquer un risque.

Temps	Activité
0:00-0:15	Accroche : la température moyenne de la base est normale
0:15-0:45	Concepts : moyenne, maximum, seuil, durée de dépassement
0:45-1:30	TP : calculer les indicateurs globaux et par zone
1:30-1:55	Débrief : quels indicateurs racontent des histoires différentes ?
1:55-2:05	Pause
2:05-2:30	Concepts : agrégation trompeuse, perte d'information
2:30-3:15	Exercice : retrouver une zone critique masquée par la moyenne
3:15-3:40	Challenge : choisir seulement 3 indicateurs pour le décideur
3:40-3:55	Restitution : justification des indicateurs retenus
3:55-4:00	Synthèse

Question décisionnelle : Quel indicateur est réellement pertinent pour décider de maintenir ou non l'activité ?

Livrables : Tables d'indicateurs ; indicateur trompeur identifié ; recommandation sur les indicateurs à suivre.

Engagement : Procès de l'indicateur : un groupe défend la moyenne globale, un autre l'attaque, un troisième arbitre.

Séquence 6 - Visualisation et communication au décideur

Objectif général : Produire une visualisation claire sans sur-vendre la certitude.

Temps	Activité
0:00-0:15	Accroche : deux graphiques donnent une impression différente du même incident
0:15-0:45	Concepts : échelle, seuil, annotation, incertitude visuelle
0:45-1:30	TP : courbe temporelle par zone
1:30-1:55	Débrief : graphique utile ou trompeur ?
1:55-2:05	Pause
2:05-2:30	Concepts : briefing décisionnel, message principal, limites
2:30-3:15	TP : produire 2 visualisations et une mini-note
3:15-3:40	Brief oral : 3 minutes par groupe
3:40-3:55	Questions contradictoires du commandement
3:55-4:00	Synthèse

Question décisionnelle : Comment présenter une alerte sans donner une impression excessive de certitude ?

Livrables : 2 à 3 graphiques ; mini-rapport opérationnel ; niveau de confiance explicite ; recommandation.

Engagement : Jeu de rôle : cellule data, décideur pressé et red team.

Séquence 7 - Confiance, sécurité et robustesse de la chaîne

Objectif général : Relier sécurité, intégrité des données et qualité de décision.

Temps	Activité
0:00-0:15	Accroche : le flux contient des messages incohérents
0:15-0:45	Concepts : intégrité, authentification, ACL, injection, rejeu
0:45-1:25	Démonstration : broker ouvert vs broker protégé
1:25-1:55	Exercice : identifier les vulnérabilités d'une chaîne MQTT
1:55-2:05	Pause
2:05-2:30	Concepts : confiance dans la source, confiance dans le traitement
2:30-3:15	Analyse d'un lot suspect : doublons, timestamps, ruptures
3:15-3:40	Matrice : incident réel, panne capteur, problème réseau, suspicion data
3:40-3:55	Décision : peut-on agir sur ces données ?
3:55-4:00	Synthèse

Question décisionnelle : Que vaut une décision opérationnelle si l'on ne peut pas qualifier la confiance dans la chaîne de données ?

Livrables : Matrice des risques data/cyber ; diagnostic de confiance ; recommandations de sécurisation minimale.

Engagement : Classement des hypothèses par probabilité et impact.

Séquence 8 - Mini-projet décisionnel final

Objectif général : Mettre les étudiants en situation complète avec un lot ambigu et une décision à défendre.

Temps	Activité
0:00-0:15	Brief mission : situation opérationnelle et décision attendue
0:15-0:35	Analyse rapide du lot et stratégie de traitement
0:35-1:30	Travail groupe : extraction, parsing, nettoyage
1:30-1:55	Travail groupe : indicateurs et visualisations
1:55-2:05	Pause
2:05-2:45	Travail groupe : note de décision
2:45-3:20	Préparation du brief oral
3:20-3:50	Restitutions courtes
3:50-4:00	Synthèse finale

Question décisionnelle : Quelle décision recommandez-vous, avec quel niveau de confiance, et quelles incertitudes doivent être communiquées au décideur ?

Livrables : Dossier de traitement ; fichiers propres et rejetés ; visualisations ; note de décision ; présentation courte.

Engagement : Brief opérationnel : situation, données/indicateurs, décision/confiance, limites/vérifications.

10. Dispositifs d'engagement transversaux

Dispositif	Principe	Intérêt pédagogique
Vote avant / après	Décision intuitive au début, décision après analyse à la fin.	Montrer comment la pipeline confirme, nuance ou change une décision.
Échelle de confiance	0 impossible, 1 faible, 2 modérée, 3 forte.	Forcer l'explicitation de l'incertitude.
Incident injecté	Capteur absent, timestamp incohérent, mauvaise unité, pic isolé, doublon.	Maintenir l'engagement et révéler les fragilités.
Red team	Un groupe attaque la conclusion d'un autre groupe.	Identifier ce qui pourrait rendre la décision fausse.
Brief décideur	Décision, confiance, arguments, limites, action terrain.	Passer du résultat technique à la recommandation opérationnelle.
Comparaison de pipelines	Deux groupes font des choix de traitement différents.	Mesurer l'effet des choix techniques sur la décision.
One chart, one decision	Chaque graphique répond à une question décisionnelle.	Éviter les visualisations décoratives ou trompeuses.
Journal des choix	Tracer les choix de rejet, correction, seuil, agrégation.	Rendre la décision auditable et défendable.

11. Compétences évaluées

Dimension	Compétences attendues
Compétences techniques minimales	Extraire les messages MQTT ; sauvegarder les données brutes ; parser le JSON ; nettoyer les données ; produire une table exploitable ; calculer des indicateurs simples ; visualiser les résultats.
Esprit critique décisionnel	Recommander une décision ; expliciter le niveau de confiance ; identifier les données qui fragilisent la conclusion ; repérer les indicateurs trompeurs ; proposer des vérifications terrain.

12. Critères d'évaluation possibles

Critère	Attendu
Compréhension du scénario	Relier les données capteurs à une situation opérationnelle.
Extraction	Récupérer correctement les messages depuis le broker simulé.
Traçabilité	Conserver les données brutes et le lien avec les messages sources.
Qualité des données	Identifier erreurs, doublons, valeurs manquantes et incohérences.
Transformation	Produire une table exploitable et documentée.
Indicateurs	Choisir des indicateurs pertinents pour la décision.
Visualisation	Produire des graphiques lisibles et non trompeurs.
Recommandation	Formuler une décision opérationnelle claire.
Incertitude	Expliciter le niveau de confiance et les limites.
Esprit critique	Identifier ce qui pourrait rendre la conclusion fausse.

13. Message pédagogique central

À retenir

Une pipeline de données transforme des messages techniques en éléments de décision. Chaque choix de traitement peut augmenter ou diminuer la confiance dans la décision.

Les étudiants doivent comprendre que produire un graphique ne suffit pas. Il faut être capable d'expliquer ce que les données permettent d'affirmer, ce qu'elles ne permettent pas de conclure, les incertitudes restantes, les risques opérationnels, les vérifications nécessaires et le niveau de confiance de la recommandation.